

AGORA — PRD FINAL (единый источник правды)

Дата: 23.07.2026 · **Ревизия:** 27.07.2026 · **Статус:** консолидирует PRD v1.0–v1.4 + все решения интервью + пять фич, заказанных после интервью (§20). **Заменяет** предыдущие версии как основной документ. Операционные артефакты (петля, верификатор, промпты, граф задач) — отдельно (см. §19).

1. Executive Summary

Оценить сериал/ролик до релиза сегодня дорого и медленно (офлайн фокус-группа — недели и десятки тысяч рублей за один показ в одном городе). **AGORA** генерирует синтетическую аудиторию из AI-персон (цифровых двойников зрителей) по соцдем-параметрам, «показывает» им видео и за минуты выдаёт аналитический отчёт — усреднённо по аудитории и по каждой персоне. Отличие от «спросить у LLM»: (1) заземление на реальный grounding-корпус фокус-групп (165 карточек респондентов), (2) реальный анализ видео (транскрипт+диаризация+разбор сцен), (3) калибровка оценок по реальным распределениям, (4) изоляция ответов + QA-верификация, (5) периметр РФ / self-host. ЦА — студии, онлайн-кинотеатры, продюсерские центры; MVP — команды ≤ 10 , мультиарендно. Позиционирование: **«прогноз, а не догадка»**.

2. Цели

Бизнес: $\times$ кратно дешевле офлайн-группы; time-to-insight недели $\rightarrow$ часы; платящие пилоты студий; expansion через переиспользование персон/портретов.

Пользователь: сигнал «зайдёт/не зайдёт» и *почему* до релиза; посегментные и по-персонные инсайты со ссылками на сцены; итерация контента; сопоставимость между роликами на одной аудитории. **Не-цели:** замена реального исследования спроса; биометрия/RL-модели (Phase-2+); публичное SaaS/биллинг на MVP; YouTube без скачивания; статистическая репрезентативность.

3. Decision Log (зафиксировано в интервью)

#	Решение	Итог
1	Модели	Qwen 3.6 (текст+кадры→JSON) через OpenAI-совм. API timeweb.cloud ; Whisper+диаризация self-host на VPS ; GPU не нужен
2	Режимы	Короткое+длинное строим одновременно; первый green — e2e_short , затем e2e_long
3	Async	Valkey + Celery + SSE ; LangGraph внутри Celery-задачи
4	Репо	Один монорепо (apps/web + services/agent-core + packages/shared + ...); контракт TS↔Python через canonical JSON Schema
5	VLM/ СТОИМОСТЬ	PySceneDetect + дедупликация кадров + панели×4 + кэш ; кап вызовов — переключатель в Настройках, дефолт «АВТО»
6	STT	faster-whisper large-v3 int8 CPU + параллельные сегменты ; Silero VAD → pyannote community-1 по речевым участкам; turbo — fallback
7	Persona DNA	8 категорий (эксперт АYA), Big Five 1–5, «зритель» вместо «потребитель», guardrail «ответ ограничен профилем»
8	Дискуссия	C : групповой синтез в Analytics; полный AI-модератор — Phase-2
9	Auth	Auth.js self-host , «команда=арендатор», RLS, роли owner/member
10	Надёжность	«Перекрытие» (replication_count) — параметр запуска; golden-сеты ×3 — внутренний гейт
11	Калибровка	Статическая в MVP (сверка с корпусом + версионированные выходы); непрерывная — Phase-2
12	Исполнение	Вариант B: /goal -петлю гоняет агент-исполнитель в среде пользователя

#	Решение	Итог
13	Граница данных	Исходное видео и полный аудиотрек не покидают контур ни при каких настройках ; наружу — только панели кадров, фрагменты транскрипта и срезы Content Pack (§7.1)
14	Таймкоды	Единственный источник — проxy-видео после ffprobe -валидации и нормализации; от него считают транскрипт, сцены, кадры и цитаты (§7.2)
15	Content Pack	Две формы : компактная в массовый прогон, полная — в контрольный глубокий просмотр по подвыборке
16	QA-стоимость	Эскалация на модель большего размера только по низкому confidence ; при незаданном QA_ESCALATION_AGENT_ID эскалации нет — это штатный режим (§14.1)
17	OCR	Отдельный OCR-контур не закладывается : в материале нет субтитров и титров, эпизодический текст читает VLM. Пересматривается при контенте с текстовой составляющей (§14.2)
18	Кэш VLM-разбора	Ключ = содержимое панели + шаблон промпта + имя модели , но НЕ task_id . По task_id перезапуск исследования (#30) не нашёл бы разбор родительской задачи, ради которого кэш и заводится. Шаблон в ключе обязателен: без него правка content.frame_analysis в Промпт-студии молча вернула бы прежний разбор
19	Жёсткий кап вызовов	Обрывает разбор исключением с частичным результатом , а не усекает список сцен. Молчаливое усечение дало бы отчёт по половине ролика, неотличимый от полного. Попадания в кэш бюджет не расходуют: кап ограничивает деньги, а кэшированная панель денег не стоит
20	Заземление критериев аудитории	Охват считается из корпуса , а не пишется строкой в интерфейсе: пополнение корпуса описано в его паспорте, то есть ожидаемо, и захардкоженное число стало бы ложью незаметно. Замерено 04.08.2026: «иные НП» — 0 из 165; поля education нет ни у одной записи , и

#	Решение	Итог
		persona_grounding этого не видит (метрика сверяет только age_group/geo/gender)
21	Критерии → генератор	Критерии сужают распределения с перенормировкой , а не фильтруют записи. Генератор сэмплирует демографию из распределений, поэтому отбор записей на состав выдачи не влияет. Пустая выборка по любому измерению — отказ с указанием виновного критерия, а не ноль персон

Решения 13–17 приняты 31.07.2026 по итогам разбора ТКП стороннего исполнителя ([docs/tkp_agency_review.md](#)), где медиаконтур проработан детальнее нашего.

4. User Stories

- **Продюсер/шоураннер:** хочу за час сводный балл и разбор по сегментам, чтобы решить go/no-go до релиза.
- **Сценарист/режиссёр:** хочу видеть проседающие сцены и почему (цитаты+таймкоды), чтобы точно переработать.
- **Маркетинг-аналитик:** хочу посегментные метрики (NPS, ретеншн, эмоции) для позиционирования.
- **Research lead:** хочу настраивать аудиторию/анкету/промпы и доверять заземлению.
- **Исследователь:** хочу переиспользовать набор персон на новом ролике для сопоставимости.
- **Владелец команды:** хочу изоляцию данных студии от других арендаторов.

5. Функциональные требования (P0/P1/P2 по impact)

А. Аудитория и персоны. P0 генерация по критериям (пол/возраст бгр/гео 3/образование)

- размер; P0 **карточка персоны + раздел «Персоны»** (плашки с датой → карточка: имя, должность, местонахождение, поколение, род занятий, карьерный опыт, хобби + Big Five 1–5); P1 реестр и переиспользование **persona_set** (преселект «Создать/Выбрать существующую»). **В. Контент.** P0 загрузка mp4/mov/avi ≤700 МБ + выбор режима (короткое/длинное). **С. Опрос.** P0 5 критериев 1–10; P1 конструктор (шкала/эмоции/удержание/рекомендация/открытый). **Д. Прогон.** P0 запуск (task_id) + **«Перекрытие»** + прогресс SSE; P0 обработка видео + изолированная оценка; P1 QA (консистентность/галлюцинации/разнообразие). **Е. Отчёт.** P0 агрегат (5 критериев, NPS, ретеншн, эмоц.индекс, топ-эмоции) + аккордеон по персонам; P1 **групповой синтез** (темы/согласие-несогласие/цитаты) + доверительные границы (при replication>1) + дисклеймер «экспертная проверка»; P1 **«Поделиться»** (публичная read-only ссылка с токеном, TTL и revoke — §20.2); P2 экспорт PDF. **Ф. Знания/настройка.** P1 портреты аудиторий (.md-редактор + авто-дистилляция из датасета); P1 Промпт-студия; P1 grounding-датасет (XLS+DOCX); P0 **Настройки** (кап стоимости/Whisper/replication по умолчанию); P1 **файл доп. контекста об аудитории** на шаге генерации персон (§20.4). **Г. Мультиарендность.** P0 RLS-изоляция, команды/пользователи/роли. **Н. Диалог и итерация (после первого green-гейта).** P1 **чат по результатам** в двух режимах — аналитик по всему исследованию и допрос конкретной персоны (§20.1); P1 **перезапуск с той же аудиторией и новыми вопросами** (§20.3).

6. User Experience

Точки входа: внутренний инструмент студии по приглашению; демо-прогон на коротком ролике. **FTUE:** создание/вступление в команду → тур из 3 шагов (выбрать/сгенерировать аудиторию → загрузить короткое видео → запустить → отчёт); пресеты + базовая анкета снижают порог. **Core:** визард 7 шагов; левое меню — Проекты, **Персоны**, Портреты аудиторий, Промпт-студия, Настройки. Раздел «Персоны»: сетка плашек → карточка (атрибуты §5.A + Big Five 1–5 визуализировано). Отчёт: агрегат+графики сверху, аккордеон по персонам снизу. **Advanced:** переиспользование персон; авто-дистилляция портретов; Промпт-студия с версиями и dry-run; посегментные срезы; экспорт; параметр «Перекрытие». **UI/UX:** тёмная тема; прогрессивное раскрытие; честная маркировка «гипотезы»; живой прогресс; заземляющие ссылки (таймкоды) в каждом обосновании.

7. Архитектура

Frontend (TS): Next.js App Router — UI, XState-визард, API-шлюз, отчёт, Промпт-студия, Настройки, редактор портретов, Auth.js. **Backend/ингест (Python):** FastAPI + **Celery** + **LangGraph**; ffmpeg/ffprobe, **Silero VAD**, faster-whisper large-v3, pyannote community-1. **Модели: Qwen 3.6** (мультимодальная) через OpenAI-совместимый **API timeweb.cloud** — VLM-разбор кадров и рассуждение персон; Whisper+pyannote self-host на CPU. Абстракция провайдера ([lib/ai-server.ts](https://lib.ai-server.ts), baseUrl из env). **Хранилища:** PostgreSQL+RLS; MongoDB; **Valkey** (очереди/прогресс/кэш); **S3 TimeWeb** (медиа). Docker Compose. **TypeDB не используется** (графовая БД, не вектор; сходство — вектор Phase-2). Общий контракт TS↔Python — canonical JSON Schema.

7.1 Граница данных: что покидает контур

Исходное видео и полная аудиодорожка **не передаются во внешнюю модель ни при каких настройках**. Наружу уходят только производные материалы: панели ключевых кадров (изображения), фрагменты транскрипта (текст) и структурированные срезы Content Pack. Транскрипция и диаризация выполняются на своём железе, поэтому речь целиком остаётся внутри контура.

Формулировка обязательна к соблюдению в коде: узел, отправляющий во внешний API байты медиафайла или полный аудиотрек, — дефект, а не оптимизация. Причина в том, что продукт продаётся как self-host, и «self-host» без описанной границы данных означает лишь место установки, а не то, куда уходит содержимое исследования.

7.2 Единый источник таймкодов (проху-представление)

На входе **ffprobe** проверяет пригодность файла, затем ffmpeg строит **проху-видео**: нормализованный контейнер с постоянным фреймрейтом и нулевым стартовым смещением. Все последующие таймкоды — транскрипта, границ сцен, ключевых кадров, цитат в отчёте — считаются от него.

Без этого шага `ffmpeg` при извлечении аудио, `PySceneDetect` при нарезке сцен и плеер в интерфейсе считают время независимо. На переменном фреймрейте и при ненулевом `start_time` они расходятся, и расхождение проявляется поздно — как «модель цитирует не ту сцену», то есть выглядит дефектом качества оценок, а не дефектом конвейера. Отладить его в таком виде дороже, чем предотвратить.

8. Бэкенд-пайплайн (LangGraph, внутри Celery-задачи)

State: `task_id`, `tenant_id`, `mode`, `video_ref`, `proxy_ref`, `audio_ref`, `speech_regions[]`, `segments[]`, `transcript_diarized`, `chunk_analyses_ref`, `video_understanding`, `content_pack_full`, `content_pack_compact`, `persona_ids[]`, `survey`, `replication_count`, `persona_answers[]`, `qa_flags[]`, `report`, `status`, `progress`.

```
probe_and_normalize(ffprobe → proxy-видео, единые таймкоды)
→ extract_audio → detect_speech(Silero VAD → speech_regions)
→ [WhisperX | pyannote(community-1, по речевым участкам)] →
merge_transcript
→ route(short|long) → sample_frames(PySceneDetect + fallback-интервал,
дедуп, панели×4)
→ analyze_chunks(Qwen VLM → JSON сцены, MAP через Send)
→ stitch(REDUCE: video_understanding по таймлайну, транскрипт=позвоночник)
→ pack(Content Pack: полная и компактная форма)
→ evaluate_personas(Qwen, MAP, изоляция; каждая персона ×replication_count;
пачки по 5)
→ qa(LLM-as-judge ×2: consistency/grounding/diversity; эскалация по низкому
confidence)
→ analytics(аргумент + групповой синтез + доверительные границы + нарратив)
→ REPORT_READY (+FAILED, чекпоинтер, прогресс в Valkey → SSE)
```

Диаризация по речевым участкам. Silero VAD выделяет отрезки речи, pyannote работает только по ним, границы возвращаются в глобальные таймкоды.

Диаризовать тишину, музыку и шум не нужно, а на CPU-инстансе это прямая экономия времени прогона: заявленные разработчиками pyannote 31 сек на час аудио измерены на H100 и к нашему железу не относятся. Спикеры остаются глобально консистентными: pyannote получает все речевые участки одним вызовом, а не по сегментам.

Дедупликация кадров. Из каждой сцены в VLM уходят только различающиеся кадры (порог по перцептивному хешу). Статичная сцена длиной в минуту иначе даёт

десяток почти одинаковых панелей, каждая из которых оплачивается вызовом самой дорогой части конвейера.

Content Pack в двух формах. Компактная (сжатый таймлайн, ключевые сцены, эмоциональные пики) уходит в массовый прогон респондентов; полная (все сцены, полный транскрипт, раскадровки) — в контрольный глубокий просмотр по подвыборке. При 500 респондентах разница между «каждому полный пакет» и «полный — контрольной подвыборке» измеряется разами стоимости запуска, а не процентами.

Длинное видео: сегменты ~10 мин, параллельная транскрипция+VLM, глобальные таймкоды, склейка. Кэш разбора кадров. Изоляция персон — структурная (в срезе state только своя DNA

- Content Pack + survey).

9. Persona DNA + карточка + раздел «Персоны»

DNA — 8 категорий (Big Five 1–5; ~40–60 полей MVP → 120):

1. Демография (8–10); 2. Big Five 1–5; 3. Ценности/убеждения (5–8, ВЦИОМ+соц.приоритеты+ культ.взгляд+философия+отношение к будущему); 4. **Зрительское поведение** (8+: жанры, толерантность к насилию/темпу/длине, лояльность к франшизам/актёрам, влияние рекомендаций, реакция на идеолог./рекл. посылы, ожидания от продакшена, attention span); 5. Стил общения (5–6); 6. Принятие решений (5–6: риск/обдуманность/влияние сверстников/доверие авторитету);
2. Использование технологий (4–5); 8. Интересы/образ жизни (5+). + narrative + seed. Guardrail: ответ ограничен задокументированным профилем. **Карточка персоны — полный профиль, не подмножество.** Клик по плашке открывает карточку, показывающую **все** атрибуты персоны: шапка (имя, должность, местонахождение, поколение, род занятий, карьерный опыт, хобби) + все 8 категорий DNA с подписанными полями (Big Five визуализировано) + narrative + seed. В контексте конкретного исследования карточка дополнительно показывает ответы этой персоны, её цитаты с таймкодами и кнопку «Спросить персону» (§20.1). Приёмка: ни одно непустое

поле canonical JSON Schema не теряется при рендере. **Раздел «Персоны»** в левом меню: сетка плашек (имя, поколение, род занятий, дата) → карточка.

10. Данные и grounding-корпус

Postgres (RLS по tenant_id): teams, users, projects, personas, persona_sets, audience_portraits, prompts, surveys, tasks(+prompts_snapshot,+replication_count), reports, settings. **MongoDB:** chunk_analyses, persona_answers, wizard_drafts, grounding_dataset. **S3:** video/audio/frames по task_id. **Grounding-корпус (data/grounding/unified_respondent_sessions.json, 165 записей — файл на месте, поля сверены с верификатором):** профильная карточка респондента из 8 секций (content_under_test, experiment_metadata, socio_demographics, psychographics_and_values, agora_core_scores_1_to_10, perception_and_retention, qualitative_verbatims, focus_group_verbatims, all_survey_responses). Собран из XLS-анкет + DOCX-стенограмм 4 сериалов (Константинополь/Ландыши/Сестра/Тюремный дневник), сегменты по (сериал×город). Наполнение 100% (пол, cinematography, сегмент, focus_group_verbatims). **Фактические реперы (замерено 27.07.2026, это цели калибровки):** средние баллы — overall_impression 7.34 · plot 7.58 · acting 8.12 · music 8.07 · cinematography 8.00. Распределения — возраст: 35-44 41% / 25-34 26% / 45-59 17% / 18-24 11% / 60+ 3% / 14-17 2%; гео: центры субъектов 55% / столицы 45%; пол: жен 67% / муж 33%. **⚠ Известное ограничение заземления:** третья гео-группа «иные НП» представлена **0 из 165** записей. Аудитория с этой группой генерируется без корпусного заземления — UI обязан предупреждать об этом, а выводы по ней помечать пониженной уверенностью. **Методология генерации персон из корпуса:** (1) распределения по (сериал×город×сегмент) — сэмплирование по реальным долям, не равномерно; (2) калибровка баллов по реальным средним (overall~7.3, plot~7.6, acting~8.1, music~8.1, cinematography~8; разброс 2–9) ±приоры; (3) стилевое+аргументативное заземление на verbatims (против sysorhancy); (4) ценности ВЦИОМ→ DNA; (5) сегмент-ориентированная установка к контенту; (6) представитель сегмента, не копия.

10-бис. Чат-агент по результатам (архитектурная позиция)

Чат (§20.1) — **отдельный синхронный агент, а не оркестратор**. Оркестратор — это LangGraph-поток внутри Celery-задачи: он эфемерен, завершается вместе с прогоном и не хранит диалог. Чат живёт поверх *завершённого task_id* и имеет read-only доступ к его артефактам: *report*, *persona_answers*, *video_understanding* (с таймкодами), *survey*, *qa_flags*. Данные ограничены (20–60 персон × ответы + отчёт), поэтому на MVP хватает подачи в контекст без RAG; вектор — Phase-2 вместе с §7. Треды — в Postgres (*chat_threads/chat_messages*, RLS по *tenant_id*).

11. Промпт-студия

Все промпты — в реестре *prompts* (key, stage, template с *{{плейсхолдерами}}*, variables, model_params, version, is_active, is_default), редактируются в меню. UI: список по стадиям, редактор с валидацией переменных, preview/dry-run, версии, restore default. Резолв: активная версия арендатора → дефолт. **Пиннинг версий на task** (*prompts_snapshot*) для воспроизводимости. Seed-промпты (**13**) готовы в *prompts/*: 11 исходных + *chat.analyst* и *chat.persona_followup* под §20.1.

12. Настройки (per-tenant)

Кап стоимости вызовов Qwen (дефолт «авто»/жёсткий кап); выбор Whisper large-v3/turbo; дефолт *replication_count*; конфиг провайдера (baseURL из env). Хранение tenant-scoped.

13. Метрики успеха

Пользователь: adoption, прогонов/неделю, time-to-report, CSAT, доля с переиспользованием. **Бизнес:** экономия vs офлайн, конверсия пилот→подписка, retention/expansion, платящие студии. **Технические (пороги /goal):** аптайм; success-rate пайплайна; grounding-точность; изоляция+RLS 100%; 0 секретов; субъективное качество персон/отчёта $\geq 7/10$ (blind).

Как считается grounding-точность (уточнено 27.07.2026). Порог | распределения–реальные| ≤ 0.10 по age_group/geo/gender проверяется **только на эталонном (reference) конфиге генерации** — «сгенерируй аудиторию как в корпусе», без пользовательских фильтров. Пользовательские прогоны с

произвольным составом («дай мне только 18-24») от этой проверки освобождены: иначе продуктовый сценарий выбора аудитории противоречил бы порогу. Калибровка баллов $|\text{средние} - \text{реальные}| \leq 1.0$ по каждому из 5 критериев действует **всегда**, включая пользовательские прогоны и прогоны с приложенным файлом контекста (§20.4) — именно она держит «прогноз, а не догадку».

14. Технические соображения

Интеграции: видео (файл/CDN); модели в периметре РФ через абстракцию провайдера; S3; существующий фронт. Данные/безопасность: мультиарендная RLS-изоляция; резидентность РФ; секреты из env; граница данных по §7.1; grounding-корпус — обезличивание, генерация представителей, а не копий; retention медиа. Масштабируемость: очередь/fan-out; map-reduce для длинных; горизонтальные воркеры; кэш чанков; резюмируемость.

14.1 Эскалация QA на модель большего размера

QA-судья возвращает **confidence** вместе с вердиктом. Ответы, где он ниже порога, идут на повторную проверку моделью большего размера; остальные закрываются основной. Смысл в том, что дорогая модель вызывается там, где дешёвая созналась в неуверенности, а не на каждом ответе — при 500 респондентах это разница в стоимости прогона, а не в его точности.

Реализация: **QA_ESCALATION_AGENT_ID** (отдельный агент TimeWeb со своей моделью — модель выбирается в кабинете, а не в коде, см. [docs/providers.md](#)).

Переменная необязательна. Если она не задана, эскалации нет и все проверки идут на основной модели; это штатный режим, а не деградация. Порог **QA_ESCALATION_CONFIDENCE** калибруется на первых прогонах: назначать его до того, как известно распределение **confidence**, значит выдумывать число.

14.2 Экранный текст: OCR рассмотрен и не закладывается

Отдельный OCR-контур (Tesseract/PaddleOCR) в MVP не вводится: материал заказчика не содержит субтитров и титров, а текст, попадающий в кадр

эпизодически, читает сам VLM при разборе панелей. Решение пересматривается, если в работу пойдёт контент с существенной текстовой составляющей — рекламные ролики с плашками, новостные врезки, обучающие видео.

15. Инфраструктура и деплой (TimeWeb)

Frontend Next.js (Node 24) + Backend FastAPI/Celery (Python 3.14), **Docker Compose на VPS**. Managed БД: **PostgreSQL 18 + MongoDB 8.0 + Valkey 9.1. S3 100 ГБ Standard**. VPS CPU-only (модели по API): **8 vCPU / 16 ГБ RAM / 100 ГБ NVMe**, GPU не нужен. ⚠ Whisper large-v3 CPU для длинных роликов медленный — параллельные сегменты; turbo как fallback. Новый репозиторий — с чистой истории (утёкшие ключи перевыпустить).

16. Вехи и последовательность

Ф0 Фундамент (инфра, БД+RLS, Auth, Промпт-студия, Настройки, DNA) → верификатор запускается. Ф1 Срез короткого видео end-to-end → **e2e_short green**. Ф2 Длинное видео (map-reduce) → e2e_long green. Ф3 Знания (датасет XLS+DOCX, портреты+авто-дистилляция). Ф4 Фичи после гейта + полировка: чат по результатам, «Поделиться», перезапуск с новыми вопросами, файл контекста аудитории, отчёт/экспорт, онбординг → MVP для пилотов. Ф5 post-MVP: вектор/RAG, непрерывная калибровка, AI-модератор дискуссии. Точка входа — **граф из 31 задачи** по зависимостям ([evals/state/tasks.json](#)).

17. Guiding Principles

Фокус на пользователе (go/no-go и посценная обратная связь важнее технологии); ясность и точность (явные сущности/потoki); выравнивание по SMART-целям; комплексная детализация и edge cases (пустой контент, длинные видео, дыры в данных, галлюцинации, mode collapse, сбои моделей); кросс-функциональность (исследователь/инженер/студия); гибкость и масштабируемость (абстракция провайдера, очередь, map-reduce, вектор Phase-2).

18. Нарратив

Марина — шоураннер. Готова первая серия, через месяц защита бюджета на сезон. Раньше — либо вслепую, либо три недели и очные группы в пяти городах. Сейчас она грузит серию в AGORA, берёт сохранённый набор из 40 персон, добавляет пару вопросов, ставит «Перекрытие 3» и жмёт «Запустить». Через 20 минут — отчёт: общее 7.2, но сегмент 45+ проседает на сцене насилия в 3-м акте; персона «Полина, 33» пишет: «на 14-й минуте перестала верить». Марина перемонтирует сцену, гонит на той же аудитории — 7.9. На защите — не интуиция, а сопоставимые цифры и конкретные правки. «В производство».

19. Операционные артефакты (отдельно)

- `docs/AGORA_HANDOFF.md` — передаточный документ для агента-исполнителя (там же — карта нумерации задач и журнал расхождений ревизии 27.07.2026).
- `docs/AGORA_loop_goal.md` — `/goal`-петля (верификатор/состояние/остановка/режимы).
- `evals/check.py` — внешний верификатор; `evals/state/tasks.json` — граф из 31 задачи с `blockedBy/phase/verifies/cdd/acceptance`; `loop-state.json`.
- `prompts/` — 13 seed-пром프트в (реестр Промпт-студии).
- `data/grounding/unified_respondent_sessions.json` — grounding-корпус.

20. Фичи ревизии 27.07.2026

Все четыре — **после** первого green-гейта `e2e_short` (в графе `blockedBy`: `[22, ...]`): сквозной пайплайн должен работать раньше, чем обрастать интерфейсом. В `tasks_done` входят.

20.1 Чат по результатам исследования (задача #28)

На экране результатов завершённого `task_id` — диалог в двух режимах.

«**Аналитик**» — вопросы по всему исследованию («почему сегмент 45+ просел?», «какие сцены теряют внимание?»). Отвечает только по артефактам задачи, каждый тезис — со ссылкой на таймкод или именную цитату; нет данных → честное «в этом исследовании не измерялось», без правдоподобных достроек; факт и интерпретация разделены явно (промпт `chat.analyst`). «**Спросить персону**» — допрос конкретной персоны из её карточки, как респондента после фокус-группы. В контекст подаётся **только** её DNA + video_understanding + survey + её собственные прежние ответы: та же структурная изоляция, что в основном пайплайне — персона не знает ни других персон, ни того, что участвует в исследовании. Guardrail «ответ ограничен профилем» действует: вне профиля → «не знаю», а не выдумка. Отслеживаются флаги `out_of_profile` и `contradicts_previous` (промпт `chat.persona_followup`). Архитектура — §10-бис. Стоимость: каждое сообщение — платный вызов, учитывается в капе (§12).

20.2 «Поделиться» результатом (задача #29)

Кнопка на экране отчёта создаёт **публичную read-only ссылку**: криптостойкий токен ≥128 бит, настраиваемый TTL, кнопка «Отозвать», список активных ссылок, аудит-лог просмотров. Это **единственный санкционированный обход RLS** в системе — реализуется отдельной политикой на таблице `report_shares` и обязан быть покрыт негативными тестами: истёкший токен → 410, отозванный → 410, чужой/подобранный → 404, через публичную страницу недоступны другие отчёты, другие арендаторы, чат и любые мутации. Публикуется полный отчёт; скрывание поимённых персон — опция шеринга.

20.3 Перезапуск с той же аудиторией и новыми вопросами (задача #30)

«Перезапустить с этой аудиторией» на экране результатов. Переиспользуются `persona_set` и **разбор видео родительской задачи** — VLM не пересчитывается (главная экономия, самая дорогая стадия). Анкета дополняется новыми вопросами. Память персон — **выбор пользователя, оба режима обязательны:**

- **«Допрос»** — персона получает свои прежние ответы и отвечает только на новые вопросы. Дёшево, непротиворечиво, старые баллы не двигаются; отчёт дополняется.
- **«Чистый прогон»** — вся анкета (старая + новая) задаётся заново в изоляции. Статистически чище, но прежние баллы могут поехать, и это дороже.

UI обязан объяснять последствия каждого режима для сопоставимости — это методологический выбор пользователя, а не техническая деталь. Связь прогонов — `tasks.parent_task_id`.

20.4 Файл доп. контекста для генерации аудитории (задача #31)

На шаге «Аудитория» пользователь может приложить файл с дополнительным контекстом о зрителях (pdf/docx/md/txt/xls). Файл **не создаёт нового механизма**: он дистиллируется в «портрет аудитории» существующим промптом

`portrait.distill` и подаётся в `persona.generate` дополнительной секцией.

Принцип приоритета — корпус выше файла. Файл *уточняет* персон (контекст ниши, лексика, специфика продукта), но **не переопределяет** распределения по соцдему и калибровку баллов из grounding-корпуса. Иначе продукт скатывается обратно в «спросить у LLM» и теряет своё единственное содержательное отличие. Конфликт разрешается в пользу корпуса и показывается пользователю предупреждением. Приёмка: с приложенным файлом эталонный `persona_grounding` остаётся green (§13).